




NATURAL LANGUAGE PROCESSING


4^η ΕΡΓΑΣΙΑ
BONUS

ΤΡΙΜΠΟΥ ΕΛΕΥΘΕΡΙΑ

ΕΠΙΒΛΕΠΩΝ: ΡΕΦΑΝΙΔΗΣ ΙΩΑΝΝΗΣ

ΘΕΣΣΑΛΟΝΙΚΗ 2024-2025

Περιεχόμενα



1. Εισαγωγή.....	1
2. Θεωρητικό Πλαίσιο	4
2.1 Η Μέθοδος Bootstrap	5
2.2 Το Paired Bootstrap Test.....	5
3. Μεθοδολογία Υλοποίησης.....	7
3.1 Παραμετροποίηση και Βιβλιοθήκες (Cell 1).....	7
3.2 Συνάρτηση Προσομοίωσης Προβλέψεων (Cell 2 - generate_predictions).....	8
3.3 Συνάρτηση Paired Bootstrap Test (Cell 3 - paired_bootstrap_test).....	8
3.4 Συνάρτηση Εκτέλεσης Πειράματος (Cell 4 - run_experiment)	9
3.5 Κύρια Ροή Εκτέλεσης (Cell 5)	10
3.6 Οπτικοποιήσεις (Cells 6, 6a, 6b, 6c)	10
3.7 Δημιουργία Λεπτομερούς Πίνακα Σύνοψης και Αποθήκευση σε CSV (Cell 7).....	10
3.8 Σύγκριση με την Υλοποίηση της SciPy (Cell 9)	10
4. Αποτελέσματα και Ανάλυση	11
4.1 Συνοπτική Παρουσίαση Αποτελεσμάτων	11
4.2 Λεπτομερής Πίνακας Αποτελεσμάτων	11
4.3 Ανάλυση ανά Μέγεθος Δείγματος (N)	12
4.3.1 Για N = 100 (Μικρό Μέγεθος Δείγματος):	12
4.3.2 Για N = 1000 (Μεσαίο Μέγεθος Δείγματος):	12
4.3.3 Για N = 10000 (Μεγάλο Μέγεθος Δείγματος):	13
4.3.4 Συνολικά, η ανάλυση ανά μέγεθος δείγματος καταδεικνύει ότι:	13
4.4 Οπτική Ανάλυση Αποτελεσμάτων	14

4.4.1 Κατανομή Bootstrap	14
4.4.2 Τάσεις P-values.....	15
4.5 Σύγκριση με την Υλοποίηση της SciPy	18
5. Συμπεράσματα.....	19

1. Εισαγωγή

Η παρούσα εργασία επικεντρώνεται στην υλοποίηση και εφαρμογή μιας στατιστικής τεχνικής, του "Paired Bootstrap Test", με σκοπό τη σύγκριση της απόδοσης δύο ταξινομητών, του Ταξινομητή A και του Ταξινομητή B. Η βασική υπόθεση της άσκησης είναι ότι διαθέτουμε ένα σύνολο δεδομένων με N παραδείγματα, και γνωρίζουμε τις πραγματικές ακρίβειες των δύο ταξινομητών: $AccA = 0.85$ για τον Ταξινομητή A και $AccB = 0.70$ για τον Ταξινομητή B. Ωστόσο, κατά την προσομοίωση, οι παρατηρούμενες ακρίβειες σε ένα συγκεκριμένο δείγμα θα προκύψουν στοχαστικά, αντανakλώντας την τυχαιότητα που υπάρχει σε πραγματικά πειράματα.

Το ζητούμενο της άσκησης ήταν να υλοποιήσω σε Python μια διαδικασία που περιλαμβάνει:

- α) Την προσομοίωση της ταξινόμησης (σωστή/λανθασμένη) κάθε παραδείγματος από τους δύο ταξινομητές, για τρία διαφορετικά μεγέθη δείγματος: $N = 100$, $N = 1000$ και $N = 10000$.
- β) Την εφαρμογή του paired bootstrap test, δημιουργώντας 10^6 bootstrap samples για κάθε μέγεθος δείγματος.
- γ) Τον έλεγχο, με τη χρήση p-value και όριο σημαντικότητας $\alpha = 0.01$, τριών συγκεκριμένων εναλλακτικών υποθέσεων ($H1$) έναντι των αντίστοιχων μηδενικών ($H0$).

Οι υποθέσεις αυτές αφορούν τη διαφορά στην ακρίβεια των δύο ταξινομητών:

1. $H1: AccA > AccB$
2. $H1: AccA > AccB + 0.05$
3. $H1: AccA > AccB + 0.1$

Επιπλέον, η άσκηση ζητούσε τη σύγκριση των αποτελεσμάτων της δικής μου υλοποίησης με αυτά που θα προκύπταν από μια υπάρχουσα υλοποίηση του paired bootstrap test, όπως αυτή που παρέχεται από τη βιβλιοθήκη SciPy της Python.

2. Θεωρητικό Πλαίσιο

2.1 Η Μέθοδος Bootstrap

Η μέθοδος Bootstrap αποτελεί μια τεχνική επαναδειγματοληψίας. Η θεμελιώδης ιδέα της είναι η προσέγγιση της άγνωστης πραγματικής κατανομής ενός πληθυσμού, χρησιμοποιώντας την εμπειρική κατανομή που προκύπτει από το διαθέσιμο δείγμα. Αυτό επιτυγχάνεται με την επανειλημμένη δημιουργία "bootstrap samples". Κάθε τέτοιο δείγμα δημιουργείται μέσω δειγματοληψίας με αντικατάσταση από το αρχικό δείγμα δεδομένων, και έχει το ίδιο μέγεθος (n) με το αρχικό δείγμα. Επειδή η δειγματοληψία γίνεται με αντικατάσταση, ορισμένες παρατηρήσεις από το αρχικό δείγμα μπορεί να εμφανιστούν πολλαπλές φορές σε ένα bootstrap sample, ενώ άλλες μπορεί να μην εμφανιστούν καθόλου.

Για κάθε ένα από τα B bootstrap samples που δημιουργούνται (όπου B είναι ένας μεγάλος αριθμός, π.χ., 1000, 10000, ή ακόμα και 10^6 όπως στην άσκησή μας), υπολογίζουμε την τιμή του στατιστικού μεγέθους που μας ενδιαφέρει (π.χ., μέσος όρος, διάμεσος, διαφορά μέσων όρων, διαφορά ακριβειών). Η συλλογή αυτών των B τιμών του στατιστικού μεγέθους σχηματίζει την εμπειρική κατανομή bootstrap, η οποία μπορεί να χρησιμοποιηθεί για την εκτίμηση της τυπικής απόκλισης του στατιστικού, την κατασκευή διαστημάτων εμπιστοσύνης, ή την πραγματοποίηση ελέγχων υποθέσεων.

2.2 To Paired Bootstrap Test

Το "Paired Bootstrap Test" είναι μια εξειδικευμένη εφαρμογή της μεθόδου bootstrap για τη σύγκριση δύο συστημάτων A και B , όταν οι μετρήσεις απόδοσής τους προέρχονται από τα ίδια δεδομένα εισόδου. Για παράδειγμα, όταν συγκρίνουμε δύο ταξινομητές, τους αξιολογούμε στο ίδιο σύνολο δοκιμής N παραδειγμάτων. Για κάθε παράδειγμα i , έχουμε ένα ζεύγος αποτελεσμάτων (πρόβλεψη_ A_i , πρόβλεψη_ B_i). Αντί να επαναδειγματοληπτούμε ξεχωριστά τις επιδόσεις των A και B , επαναδειγματοληπτούμε αυτά τα ζεύγη.

Στο πλαίσιο της σύγκρισης ταξινομητών, το στατιστικό που μας ενδιαφέρει είναι η διαφορά στις ακρίβειές τους, $\delta = AccA - AccB$. Ο αλγόριθμος, όπως περιγράφεται και στο σύγγραμμά μας, προσαρμόζεται ως εξής για τον έλεγχο υποθέσεων:

1. Αρχικό Δείγμα και Παρατηρούμενη Διαφορά: Από το αρχικό σύνολο N παραδειγμάτων, υπολογίζουμε τις παρατηρούμενες ακρίβειες $AccA_{\text{παρατηρούμενη}}$ και $AccB_{\text{παρατηρούμενη}}$, και την παρατηρούμενη διαφορά $\delta_{\text{παρατηρούμενη}} = AccA_{\text{παρατηρούμενη}} - AccB_{\text{παρατηρούμενη}}$.
2. Bootstrap Επανάληψεις (B φορές):
 - Για κάθε επανάληψη j (από 1 έως B):
 - Δημιουργούμε ένα bootstrap sample επιλέγοντας τυχαία, με αντικατάσταση, N ζεύγη προβλέψεων [(πρόβλεψη_ A_i , πρόβλεψη_ B_i), ...] από τα αρχικά N ζεύγη.

- Για αυτό το bootstrap sample, υπολογίζουμε τις ακρίβειες $AccA_boot(j)$ και $AccB_boot(j)$.
- Υπολογίζουμε τη διαφορά των ακριβειών: $\delta_boot(j) = AccA_boot(j) - AccB_boot(j)$.

3. Έλεγχος Υπόθεσης (π.χ., $H1: AccA > AccB + \Delta$):

- Η μηδενική υπόθεση ($H0$) είναι: $AccA - AccB \leq \Delta$.
- Το p-value υπολογίζεται ως το ποσοστό των bootstrap διαφορών $\delta_boot(j)$ που υποστηρίζουν την $H0$ (δηλαδή, είναι μικρότερες ή ίσες από το Δ).

$$p - value = (\text{αριθμός των } \delta_boot(j) \leq \Delta) / B$$

4. Συμπέρασμα: Αν το p-value είναι μικρότερο από ένα προκαθορισμένο επίπεδο σημαντικότητας α , απορρίπτουμε την $H0$ υπέρ της $H1$. Αυτό σημαίνει ότι η παρατηρούμενη διαφορά είναι στατιστικά σημαντική και είναι απίθανο να έχει προκύψει τυχαία αν η $H0$ ήταν αληθής.

3. Μεθοδολογία Υλοποίησης

Η υλοποίηση του πειράματος πραγματοποιήθηκε στο περιβάλλον της Kaggle, σε ένα Jupyter Notebook, χρησιμοποιώντας τη γλώσσα Python και τις βιβλιοθήκες NumPy για αριθμητικούς υπολογισμούς, Pandas για τη διαχείριση και παρουσίαση των δεδομένων, και Matplotlib/Seaborn για τις οπτικοποιήσεις. Η διαδικασία που ακολούθησα αναλύεται παρακάτω, με αναφορά στα αντίστοιχα κελιά του notebook.

3.1 Παραμετροποίηση και Βιβλιοθήκες (Cell 1)

Το πρώτο βήμα ήταν η εισαγωγή των απαραίτητων βιβλιοθηκών και ο ορισμός των παραμέτρων του πειράματος. Αυτές οι παράμετροι συγκεντρώθηκαν σε ένα λεξικό με το όνομα CONFIG για ευκολία διαχείρισης και τροποποίησης. Συγκεκριμένα, ορίστηκαν:

- `ACC_A_TRUE = 0.85`: Η πραγματική (θεωρητική) ακρίβεια του Ταξινομητή A.
- `ACC_B_TRUE = 0.70`: Η πραγματική (θεωρητική) ακρίβεια του Ταξινομητή B.
- `SAMPLE_SIZES = [100, 1000, 10000]`: Τα τρία διαφορετικά μεγέθη δείγματος (N) που θα εξεταστούν.
- `B_REPLICATIONS = 1_000_000`: Ο αριθμός των bootstrap επαναλήψεων για την κύρια ανάλυση, όπως ζητήθηκε στην εκφώνηση.
- `B_REPLICATIONS_VIS_DIST = 10_000`: Μικρότερος αριθμός επαναλήψεων για τη γρήγορη δημιουργία του ιστογράμματος της κατανομής bootstrap.
- `B_REPLICATIONS_COMPARE = 10_000`: Μικρότερος αριθμός επαναλήψεων για τη σύγκριση με τη SciPy, για λόγους ταχύτητας.
- `P_VALUE_THRESHOLD = 0.01`: Το όριο σημαντικότητας α για τον έλεγχο των υποθέσεων.
- `CONFIDENCE_LEVEL = 0.99`: Το επίπεδο εμπιστοσύνης για τον υπολογισμό των διαστημάτων εμπιστοσύνης (CIs).
- `DELTAS = [0.0, 0.05, 0.10]`: Οι τιμές Δ που χρησιμοποιούνται στις τρεις εναλλακτικές υποθέσεις $H1: AccA > AccB + \Delta$.
- `RANDOM_SEED = 42`: Ένας τυχαίος σπόρος για την εξασφάλιση της αναπαραγωγιμότητας των αποτελεσμάτων.
- Ονόματα αρχείων εξόδου για τον πίνακα CSV και τα γραφήματα.
Επίσης, σε αυτό το κελί ρυθμίστηκε η βιβλιοθήκη logging για την καλύτερη παρακολούθηση της εκτέλεσης του κώδικα και την καταγραφή πληροφοριών ή προειδοποιήσεων.

3.2 Συνάρτηση Προσομοίωσης Προβλέψεων (Cell 2 - `generate_predictions`)

Δημιούργησα τη συνάρτηση `generate_predictions(n_samples, acc_a, acc_b, seed=None)` η οποία αναλαμβάνει να προσομοιώσει τις εξόδους (σωστή ή λανθασμένη ταξινόμηση) των δύο ταξινομητών A και B για ένα δεδομένο μέγεθος δείγματος `n_samples`.

- Για κάθε ταξινομητή (A και B ξεχωριστά) και για κάθε ένα από τα `n_samples` δείγματα:
 - Παράγεται ένας τυχαίος αριθμός μεταξύ `[0, 1)` χρησιμοποιώντας τη `rng.random()`, όπου `rng` είναι ένα αντικείμενο `np.random.RandomState` αρχικοποιημένο με τον παρεχόμενο `seed` (ή το global `np.random` αν δεν δοθεί `seed`).
 - Αν ο τυχαίος αριθμός είναι μικρότερος από την πραγματική ακρίβεια του ταξινομητή (`acc_a` ή `acc_b`), τότε η πρόβλεψη για το συγκεκριμένο δείγμα θεωρείται σωστή (αναπαρίσταται με 1).
 - Διαφορετικά, η πρόβλεψη θεωρείται λανθασμένη (αναπαρίσταται με 0).
- Η συνάρτηση επιστρέφει δύο πίνακες NumPy, `pred_a` και `pred_b`, που περιέχουν τις δυαδικές προβλέψεις (0 ή 1) για κάθε ταξινομητή για όλα τα δείγματα.

3.3 Συνάρτηση Paired Bootstrap Test (Cell 3 - `paired_bootstrap_test`)

Αυτή η συνάρτηση, `paired_bootstrap_test(pred_a, pred_b, num_bootstraps, deltas, confidence_level=0.99, seed=None, return_distribution=False)`, υλοποιεί τον πυρήνα του Paired bootstrap Test.

- Είσοδοι: Οι πίνακες προβλέψεων `pred_a`, `pred_b`, ο αριθμός bootstrap επαναλήψεων `num_bootstraps`, μια λίστα με τις τιμές `deltas` για τις οποίες θα ελεγχθούν οι υποθέσεις, το επιθυμητό επίπεδο εμπιστοσύνης `confidence_level`, ένας προαιρετικός τυχαίος `seed`, και μια boolean μεταβλητή `return_distribution` που καθορίζει αν θα επιστραφεί ολόκληρη η κατανομή των bootstrap διαφορών.
- Διαδικασία Επαναδειγματοληψίας:
 - Αρχικοποιείται ένας πίνακας `diff_scores` για την αποθήκευση των διαφορών ακρίβειας από κάθε bootstrap δείγμα.
 - Εκτελείται ένας βρόχος για `num_bootstraps` επαναλήψεις. Σε κάθε επανάληψη `i`:
 - Επιλέγονται `n_samples` (όπου `n_samples` είναι το μήκος των `pred_a`, `pred_b`) τυχαίοι δείκτες με αντικατάσταση από το εύρος `[0, n_samples-1]`. Αυτό δημιουργεί τους δείκτες για το `i`-οστό bootstrap δείγμα.

- Χρησιμοποιώντας αυτούς τους δείκτες, υπολογίζονται οι ακρίβειες `acc_a_boot` (μέσος όρος των `pred_a[indices]`) και `acc_b_boot` (μέσος όρος των `pred_b[indices]`) για το τρέχον bootstrap δείγμα.
- Η διαφορά $diff_scores[i] = acc_a_boot - acc_b_boot$ αποθηκεύεται.
- Υπολογισμός P-values: Μετά τη δημιουργία της κατανομής των `diff_scores`:
 - Για κάθε `delta` στη λίστα `deltas`, το p-value υπολογίζεται ως $np.mean(diff_scores \leq delta)$. Αυτό αντιστοιχεί στον έλεγχο της μηδενικής υπόθεσης $H0: AccA - AccB \leq \Delta$ έναντι της εναλλακτικής $H1: AccA - AccB > \Delta$. Ένα μικρό p-value υποδηλώνει ότι τα δεδομένα δεν συνάδουν με την $H0$.
- Υπολογισμός Διαστήματος Εμπιστοσύνης (CI):
 - Υπολογίζεται το κάτω και το άνω ποσοστημόριο της ταξινομημένης κατανομής `diff_scores` που αντιστοιχούν στο ζητούμενο `confidence_level`. Για 99% CI, αυτά είναι το 0.5ο και 99.5ο ποσοστημόριο.
 - Τα `ci_lower = np.percentile(diff_scores, lower_percentile)` και `ci_upper = np.percentile(diff_scores, upper_percentile)` ορίζουν το διάστημα εμπιστοσύνης.
- Έξοδος: Η συνάρτηση επιστρέφει τα p-values και το CI. Αν `return_distribution` είναι `True`, επιστρέφει και τον πίνακα `diff_scores`.

3.4 Συνάρτηση Εκτέλεσης Πειράματος (Cell 4 - run_experiment)

Η συνάρτηση `run_experiment(config_params)` οργανώνει ολόκληρο το πείραμα για όλα τα μεγέθη δείγματος που καθορίζονται στο `config_params["SAMPLE_SIZES"]`.

- Για κάθε μέγεθος δείγματος `n_current` στη λίστα:
 - Παράγονται οι αρχικές προβλέψεις `predictions_a`, `predictions_b` καλώντας την `generate_predictions`. Ένας μοναδικός `simulation_seed` χρησιμοποιείται για κάθε `N` για την παραγωγή αυτών των δεδομένων.
 - Υπολογίζονται οι παρατηρούμενες ακρίβειες `observed_acc_a`, `observed_acc_b` και η παρατηρούμενη διαφορά `observed_diff`.
 - Καλείται η `paired_bootstrap_test` με τις `predictions_a`, `predictions_b`, τον μεγάλο αριθμό επαναλήψεων `config_params["B_REPLICATIONS"]` (10^6), τη λίστα `config_params["DELTAS"]`, και ένα μοναδικό `bootstrap_seed` για κάθε `N`.

- Τα αποτελέσματα (παρατηρούμενες τιμές, p-values για κάθε Δ , διάστημα εμπιστοσύνης, και μια boolean λίστα `reject_h0` που δείχνει αν η H_0 απορρίπτεται για κάθε Δ) αποθηκεύονται σε ένα λεξικό `results_log` με κλειδί το `n_current`.
- Η συνάρτηση επιστρέφει το `results_log`.

3.5 Κύρια Ροή Εκτέλεσης (Cell 5)

Εδώ, καλείται η `run_experiment(CONFIG)` για να ξεκινήσει το πείραμα. Τα αποτελέσματα αποθηκεύονται στη μεταβλητή `results`. Ακολουθεί μια εκτύπωση μιας σύνοψης των αποτελεσμάτων από το λεξικό `results`.

3.6 Οπτικοποιήσεις (Cells 6, 6a, 6b, 6c)

- 3.6.1 Γραφήματα Τάσης P-value (Cells 6 & 6a): Δημιουργούνται γραφήματα που δείχνουν την τάση των p-values ως προς το N.
- 3.6.2 Γραφήματα Τάσης Διαστημάτων Εμπιστοσύνης (Cell 6b): Παράγονται γραφήματα που δείχνουν την τάση των 99% CIs ως προς το N.
- 3.6.3 Αντιπροσωπευτική Κατανομή Bootstrap (Cell 6c): Δημιουργείται ιστόγραμμα της κατανομής bootstrap για $N=1000$, $\Delta=0.0$.

3.7 Δημιουργία Λεπτομερούς Πίνακα Σύνοψης και Αποθήκευση σε CSV (Cell 7)

Τα δεδομένα από το `results` μετατρέπονται σε Pandas DataFrame και αποθηκεύονται σε CSV.

3.8 Σύγκριση με την Υλοποίηση της SciPy (Cell 9)

Υλοποιείται η συνάρτηση `scipy_paired_bootstrap_metrics(...)` που χρησιμοποιεί την `scipy.stats.bootstrap` για υπολογισμό CIs (μέθοδος 'BCa') και p-values. Τα αποτελέσματα συγκρίνονται με τη δική μου υλοποίηση.

4. Αποτελέσματα και Ανάλυση

Τα αποτελέσματα του πειράματος, που διεξήχθη για τρία διαφορετικά μεγέθη δείγματος ($N = 100, 1000, 10000$) και τρεις διαφορετικές υποθέσεις για τη διαφορά στην ακρίβεια των ταξινομητών A και B, παρουσιάζονται παρακάτω. Η πραγματική ακρίβεια του A ήταν 0.85 και του B 0.70 (πραγματική διαφορά 0.15). Ο έλεγχος έγινε με επίπεδο σημαντικότητας $\alpha = 0.01$ και υπολογίστηκαν 99% Διαστήματα Εμπιστοσύνης (CI) για τη διαφορά $AccA - AccB$.

4.1 Συνοπτική Παρουσίαση Αποτελεσμάτων

Η αρχική εκτέλεση του πειράματος (Cell 5) παρήγαγε την ακόλουθη σύνοψη:

Επεξεργασία Μεγεθών Δείγματος (N): 100% 3/3 [04:49:00:00, 122.19s/it]

===== ΤΕΛΙΚΗ ΣΥΝΟΨΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ (από το λεξικό results) =====

Αποτελέσματα για $N = 100$:

Παρατηρούμενη AccA: 0.7900, AccB: 0.7100, Διαφορά: 0.0800

99% CI για AccA-AccB: (-0.0800, 0.2400)

H1: Acc_A > Acc_B + 0.00 -> p-value = 0.115968, Απόρριψη H0 ($\alpha=0.01$): Όχι

H1: Acc_A > Acc_B + 0.05 -> p-value = 0.298047, Απόρριψη H0 ($\alpha=0.01$): Όχι

H1: Acc_A > Acc_B + 0.10 -> p-value = 0.631546, Απόρριψη H0 ($\alpha=0.01$): Όχι

Αποτελέσματα για $N = 1000$:

Παρατηρούμενη AccA: 0.8630, AccB: 0.6980, Διαφορά: 0.1650

99% CI για AccA-AccB: (0.1190, 0.2110)

H1: Acc_A > Acc_B + 0.00 -> p-value = 0.000000, Απόρριψη H0 ($\alpha=0.01$): Ναι

H1: Acc_A > Acc_B + 0.05 -> p-value = 0.000000, Απόρριψη H0 ($\alpha=0.01$): Ναι

H1: Acc_A > Acc_B + 0.10 -> p-value = 0.000135, Απόρριψη H0 ($\alpha=0.01$): Ναι

Αποτελέσματα για $N = 10000$:

Παρατηρούμενη AccA: 0.8509, AccB: 0.7010, Διαφορά: 0.1499

99% CI για AccA-AccB: (0.1349, 0.1649)

H1: Acc_A > Acc_B + 0.00 -> p-value = 0.000000, Απόρριψη H0 ($\alpha=0.01$): Ναι

H1: Acc_A > Acc_B + 0.05 -> p-value = 0.000000, Απόρριψη H0 ($\alpha=0.01$): Ναι

H1: Acc_A > Acc_B + 0.10 -> p-value = 0.000000, Απόρριψη H0 ($\alpha=0.01$): Ναι

Αυτή η σύνοψη παρέχει μια πρώτη, γρήγορη επισκόπηση των p-values και των αποφάσεων απόρριψης της μηδενικής υπόθεσης (H0) για κάθε N και κάθε Δέλτα (Δ).

4.2 Λεπτομερής Πίνακας Αποτελεσμάτων

Για μια πιο αναλυτική εικόνα, ο παρακάτω πίνακας (από το Cell 7) συνοψίζει όλες τις παρατηρούμενες τιμές, τα p-values και τα 99% CIs:

```
===== ΛΕΠΤΟΜΕΡΗΣ ΠΙΝΑΚΑΣ ΣΥΝΟΨΗΣ ΑΠΟΤΕΛΕΣΜΑΤΩΝ (με CIs) =====
Μέγεθος Δείγματος (N)  Δέλτα (δ)  Acc_A (παρατηρ.)  Acc_B (παρατηρ.)  Acc_A - Acc_B (παρατηρ.)  p-value  Απόρριψη H0 (α=0.01)  99% CI Κάτω Όριο  99% CI Άνω Όριο
100                    0.00        0.7900           0.7100           0.0800  0.115968              Όχι                -0.0800         0.2400
100                    0.05        0.7900           0.7100           0.0800  0.298047              Όχι                -0.0800         0.2400
100                    0.10        0.7900           0.7100           0.0800  0.631546              Όχι                -0.0800         0.2400
1000                   0.00        0.8630           0.6980           0.1650  0.000000              Ναι                0.1190         0.2110
1000                   0.05        0.8630           0.6980           0.1650  0.000000              Ναι                0.1190         0.2110
1000                   0.10        0.8630           0.6980           0.1650  0.000135              Ναι                0.1190         0.2110
10000                  0.00        0.8509           0.7010           0.1499  0.000000              Ναι                0.1349         0.1649
10000                  0.05        0.8509           0.7010           0.1499  0.000000              Ναι                0.1349         0.1649
10000                  0.10        0.8509           0.7010           0.1499  0.000000              Ναι                0.1349         0.1649
```

4.3 Ανάλυση ανά Μέγεθος Δείγματος (N)

4.3.1 Για N = 100 (Μικρό Μέγεθος Δείγματος):

- Η παρατηρούμενη ακρίβεια του Ταξινομητή A ήταν 0.7900 και του Ταξινομητή B ήταν 0.7100. Αυτό οδήγησε σε μια παρατηρούμενη διαφορά ($AccA - AccB$) της τάξης του 0.0800.
- Εξετάστηκαν οι ακόλουθες υποθέσεις (με $\alpha=0.01$):
 - $H1: AccA > AccB$ ($\Delta = 0.00$): Το p-value ήταν 0.115968. Καθώς $0.115968 > 0.01$, δεν απορρίπτουμε τη μηδενική υπόθεση ($H0$) ότι $AccA \leq AccB$.
 - $H1: AccA > AccB + 0.05$ ($\Delta = 0.05$): Το p-value ήταν 0.298047. Καθώς $0.298047 > 0.01$, δεν απορρίπτουμε την $H0$ ότι $AccA \leq AccB + 0.05$.
 - $H1: AccA > AccB + 0.10$ ($\Delta = 0.10$): Το p-value ήταν 0.631546. Καθώς $0.631546 > 0.01$, δεν απορρίπτουμε την $H0$ ότι $AccA \leq AccB + 0.10$.
- Το 99% Διάστημα Εμπιστοσύνης (CI) για την πραγματική διαφορά $AccA - AccB$ υπολογίστηκε ως (-0.0800, 0.2400). Αυτό το διάστημα είναι αρκετά ευρύ και περιλαμβάνει το 0, καθώς και τις τιμές 0.05 και 0.10. Η συμπερίληψη του 0 στο CI υποδηλώνει ότι δεν μπορούμε να είμαστε 99% βέβαιοι ότι υπάρχει διαφορά μεταξύ των ταξινομητών, πόσο μάλλον ότι αυτή υπερβαίνει τα 0.05 ή 0.10. Αυτό συνάδει με τη μη απόρριψη των $H0$.

4.3.2 Για N = 1000 (Μεσαίο Μέγεθος Δείγματος):

- Η παρατηρούμενη ακρίβεια του A ήταν 0.8630 και του B 0.6980, με παρατηρούμενη διαφορά 0.1650.
- Εξετάστηκαν οι υποθέσεις (με $\alpha=0.01$):
 - $H1: AccA > AccB$ ($\Delta = 0.00$): Το p-value ήταν 0.000000. Καθώς $0.000000 < 0.01$, απορρίπτουμε την $H0$ υπέρ της $H1$. Συμπεραίνουμε ότι ο $AccA$ είναι στατιστικά σημαντικά μεγαλύτερος από τον $AccB$.
 - $H1: AccA > AccB + 0.05$ ($\Delta = 0.05$): Το p-value ήταν 0.000000. Καθώς $0.000000 < 0.01$, απορρίπτουμε την $H0$. Συμπεραίνουμε ότι ο $AccA$ είναι στατιστικά σημαντικά μεγαλύτερος από τον $AccB$ κατά τουλάχιστον 0.05.
 - $H1: AccA > AccB + 0.10$ ($\Delta = 0.10$): Το p-value ήταν 0.000135. Καθώς $0.000135 < 0.01$, απορρίπτουμε την $H0$. Συμπεραίνουμε ότι ο $AccA$ είναι στατιστικά σημαντικά μεγαλύτερος από τον $AccB$ κατά τουλάχιστον 0.10.

- Το 99% CI για τη διαφορά $AccA - AccB$ ήταν (0.1190, 0.2110). Αυτό το διάστημα είναι εξ ολοκλήρου πάνω από το 0, το 0.05 και το 0.10. Για παράδειγμα, το κάτω όριο του CI (0.1190) είναι μεγαλύτερο από το $\Delta = 0.10$, υποστηρίζοντας την απόρριψη και της πιο αυστηρής H_0 .

4.3.3 Για $N = 10000$ (Μεγάλο Μέγεθος Δείγματος):


- Η παρατηρούμενη ακρίβεια του A ήταν 0.8509 και του B 0.7010, με παρατηρούμενη διαφορά 0.1499.
- Εξετάστηκαν οι υποθέσεις (με $\alpha=0.01$):
 - $H_1: AccA > AccB$ ($\Delta = 0.00$): Το p-value ήταν 0.000000. Απορρίπτουμε την H_0 .
 - $H_1: AccA > AccB + 0.05$ ($\Delta = 0.05$): Το p-value ήταν 0.000000. Απορρίπτουμε την H_0 .
 - $H_1: AccA > AccB + 0.10$ ($\Delta = 0.10$): Το p-value ήταν 0.000000. Απορρίπτουμε την H_0 .
- Το 99% CI για τη διαφορά $AccA - AccB$ ήταν (0.1349, 0.1649). Και πάλι, το διάστημα αυτό είναι εξ ολοκλήρου πάνω από όλες τις εξεταζόμενες τιμές Δ (0.00, 0.05, 0.10), επιβεβαιώνοντας τα συμπεράσματα από τα p-values.

4.3.4 Συνολικά, η ανάλυση ανά μέγεθος δείγματος καταδεικνύει ότι:

- Για μικρά N , η τυχαιότητα της δειγματοληψίας μπορεί να αποκρύψει πραγματικές διαφορές, οδηγώντας σε υψηλά p-values και ευρέα CIs που περιλαμβάνουν την τιμή της μηδενικής υπόθεσης.
- Καθώς το N αυξάνεται, η εκτίμηση της διαφοράς γίνεται πιο ακριβής, τα CIs στενεύουν, και τα p-values μειώνονται, επιτρέποντας την ανίχνευση διαφορών με μεγαλύτερη ισχύ.
- Τα αποτελέσματα για $N=1000$ και $N=10000$ είναι συνεπή με την πραγματικότητα ($AccA - AccB = 0.15$), καθώς το τεστ απέρριψε σωστά την H_0 για $\Delta=0.00$, $\Delta=0.05$ και $\Delta=0.10$, τιμές που είναι όλες μικρότερες ή ίσες με την πραγματική διαφορά.



4.4 Οπτική Ανάλυση Αποτελεσμάτων



4.4.1 Κατανομή Bootstrap



Η παραπάνω εικόνα (από το Cell 6c) απεικονίζει την κατανομή των bootstrap διαφορών για N=1000 και έλεγχο υπόθεσης $H_1: AccA > AccB$ (δηλαδή, $\Delta=0.00$), χρησιμοποιώντας B=10,000 επαναλήψεις. Παρατηρούμε μια κατανομή σε σχήμα καμπάνας, κεντραρισμένη γύρω από την παρατηρούμενη διαφορά (0.1650, μαύρη γραμμή). Το Δέλτα της υπόθεσης ($\Delta=0.00$, κόκκινη διακεκομμένη γραμμή) βρίσκεται σαφώς εκτός της περιοχής του 99% CI (0.1190, 0.2100, μωβ περιοχή και γραμμές), και συγκεκριμένα το σύνολο του CI βρίσκεται πάνω από την τιμή $\Delta=0.00$. Αυτό υποδεικνύει ότι η μηδενική υπόθεση ($AccA - AccB \leq 0.00$) είναι απίθανη. Το αποτέλεσμα αυτό συνάδει με το πολύ μικρό p-value (0.000000) που υπολογίστηκε για αυτή την περίπτωση, οδηγώντας στην απόρριψη της H_0 .

4.4.2 Τάσεις P-values








Τα γραφήματα αυτά, των p-values (τόσο το συνδυασμένο όσο και τα ατομικά ανά Δέλτα) επιβεβαιώνουν ότι η αύξηση του μεγέθους του δείγματος N οδηγεί σε μείωση των p-values. Για N=100, όλα τα p-values (μπλε, πορτοκαλί και πράσινη γραμμή στο συνδυασμένο plot) βρίσκονται πάνω από το όριο σημαντικότητας $\alpha=0.01$ (κόκκινη διακεκομμένη γραμμή). Καθώς το N αυξάνεται, τα p-values για όλες τις υποθέσεις μειώνονται δραματικά. Συγκεκριμένα, για N=1000 και N=10000, όλα τα p-values είναι ουσιαστικά μηδενικά, πολύ κάτω από το $\alpha=0.01$. Αυτό σημαίνει ότι με μεγαλύτερα δείγματα, η στατιστική ισχύς του τεστ αυξάνεται, επιτρέποντας την απόρριψη της H0 με μεγαλύτερη βεβαιότητα.

4.4.3 Τάσεις Διαστημάτων Εμπιστοσύνης

Τα γραφήματα των 99% Διαστημάτων Εμπιστοσύνης (CIs) για τη διαφορά $AccA - AccB$ (γαλάζια σκιασμένη περιοχή) απεικονίζουν:





Από τα γραφήματα των CIs, φαίνεται ότι για $N=100$, το διάστημα εμπιστοσύνης είναι ευρύ και περιλαμβάνει τις τιμές Δ , υποστηρίζοντας τη μη απόρριψη της H_0 . Αντίθετα, για $N=1000$ και $N=10000$, τα CIs στενεύουν και τα κάτω όριά τους υπερβαίνουν τις τιμές Δ , παρέχοντας ισχυρή ένδειξη υπέρ της H_1 . Επίσης, η πραγματική διαφορά (0.15) βρίσκεται εντός των CIs για $N=1000$ και $N=10000$, υποδεικνύοντας ότι οι εκτιμήσεις μας είναι συμβατές με την αλήθεια.

4.5 Σύγκριση με την Υλοποίηση της SciPy

Η σύγκριση των αποτελεσμάτων της υλοποίησής μου με αυτά της `scipy.stats.bootstrap` παρουσιάζεται στον παραπάνω πίνακα.

===== ΣΥΓΚΡΙΣΗ P-VALUES & CIs (Δική μας Υλοπ. vs. Βασισμένη σε SciPy) =====

Σύγκριση για N = 100 (B_compare=10,000):					
Δέλτα	P-val (Δικό μας)	P-val (SciPy)	Απόλ. Διαφ. P	CI (Δικό μας)	CI (SciPy BCa)
0.00	0.001400	0.002100	0.000700	(0.0200, 0.3200)	(0.0200, 0.3100)
0.05	0.016500	0.022200	0.005700	(0.0200, 0.3200)	(0.0200, 0.3100)
0.10	0.120400	0.123600	0.003200	(0.0200, 0.3200)	(0.0200, 0.3100)
Σύγκριση για N = 1000 (B_compare=10,000):					
Δέλτα	P-val (Δικό μας)	P-val (SciPy)	Απόλ. Διαφ. P	CI (Δικό μας)	CI (SciPy BCa)
0.00	0.000000	0.000000	0.000000	(0.1280, 0.2230)	(0.1280, 0.2230)
0.05	0.000000	0.000000	0.000000	(0.1280, 0.2230)	(0.1280, 0.2230)
0.10	0.000000	0.000000	0.000000	(0.1280, 0.2230)	(0.1280, 0.2230)
Σύγκριση για N = 10000 (B_compare=10,000):					
Δέλτα	P-val (Δικό μας)	P-val (SciPy)	Απόλ. Διαφ. P	CI (Δικό μας)	CI (SciPy BCa)
0.00	0.000000	0.000000	0.000000	(0.1248, 0.1539)	(0.1239, 0.1536)
0.05	0.000000	0.000000	0.000000	(0.1248, 0.1539)	(0.1239, 0.1536)
0.10	0.000000	0.000000	0.000000	(0.1248, 0.1539)	(0.1239, 0.1536)

Ο παραπάνω πίνακας δείχνει μια πολύ στενή συμφωνία μεταξύ των p-values που υπολογίστηκαν από τη δική μου υλοποίηση και εκείνων που προέκυψαν από τη SciPy. Οι απόλυτες διαφορές είναι αμελητέες. Τα διαστήματα εμπιστοσύνης είναι επίσης πολύ παρόμοια, με τις μικρές διαφορές να αποδίδονται στη χρήση της μεθόδου BCa από τη SciPy έναντι της μεθόδου των ποσοστημορίων της δικής μου υλοποίησης. Η μέθοδος BCa είναι γενικά πιο ακριβής, αλλά τα αποτελέσματα και από τις δύο μεθόδους οδηγούν στα ίδια συμπεράσματα σχετικά με την απόρριψη των μηδενικών υποθέσεων, γεγονός που επιβεβαιώνει την ορθότητα της υλοποίησής μου.

5. Συμπεράσματα

Από την υλοποίηση και την εκτέλεση της άσκησης αυτής, προκύπτουν τα ακόλουθα βασικά συμπεράσματα σχετικά με το paired bootstrap test και την εφαρμογή του στη σύγκριση ταξινομητών:

1. Η Ισχύς του Τεστ Αυξάνεται με το Μέγεθος του Δείγματος (N): Τα αποτελέσματά μου επιβεβαίωσαν αυτή την αρχή. Για $N=100$, παρόλο που ο ταξινομητής A είχε παρατηρούμενη διαφορά από τον B, τα p-values δεν επέτρεψαν την απόρριψη της μηδενικής υπόθεσης. Αντίθετα, για $N=1000$ και $N=10000$, όπου οι παρατηρούμενες διαφορές ήταν, τα p-values ήταν σχεδόν μηδενικά για όλες τις υποθέσεις ($AccA > AccB$, $AccA > AccB + 0.05$, $AccA > AccB + 0.10$), οδηγώντας σε απόρριψη της H_0 . Αυτό καταδεικνύει ότι μόνο με επαρκές μέγεθος δείγματος μπορώ να ανιχνεύσω με στατιστική βεβαιότητα την υπεροχή ενός ταξινομητή.
2. Ερμηνεία των P-values και των CIs: Έμαθα πώς να ερμηνεύω τα p-values στο πλαίσιο του ορίου σημαντικότητας $\alpha=0.01$ για να αποφασίσω την απόρριψη ή μη της H_0 . Τα 99% Διαστήματα Εμπιστοσύνης που υπολόγισα παρείχαν μια εναλλακτική οπτική: όταν το Δέλτα της υπόθεσης βρισκόταν εκτός (και κάτω από) το CI, η H_0 απορρίφθηκε, κάτι που ήταν συνεπές με τα p-values. Η οπτικοποίηση της κατανομής bootstrap (Plot από Cell 6c) βοήθησε στην κατανόηση αυτής της σχέσης.
3. Σημασία της Επιλογής του Δέλτα (Δ): Η άσκηση ανέδειξε πώς η επιλογή διαφορετικών τιμών Δ για την υπόθεση $H_1: AccA > AccB + \Delta$ επηρεάζει το συμπέρασμα. Ενώ για μεγάλα N απορρίψαμε την H_0 ακόμα και για $\Delta=0.10$, αυτό μπορεί να μην ισχύει αν η πραγματική διαφορά ήταν μικρότερη ή το N ανεπαρκές.
4. Επιβεβαίωση Υλοποίησης: Η σύγκριση των αποτελεσμάτων μου με αυτά της `scipy.stats.bootstrap` (Πίνακας από Cell 9) ήταν το σημείο κλειδί. Τα p-values ήταν σχεδόν πανομοιότυπα, και τα CIs, αν και υπολογισμένα με διαφορετικές μεθόδους (percentile vs BCa), ήταν πολύ κοντά και οδηγούσαν στα ίδια συμπεράσματα.
5. Πρακτική Εφαρμογή του Bootstrap: Επιτρέπει την εκτίμηση της στατιστικής σημαντικότητας χωρίς αυστηρές παραδοχές για την κατανομή των δεδομένων.